

# Projekt LVS-IR-Taubenstein

---

**Projektpartner:** Sascha Filimon, Roman Ossner

**Gruppenbetreuer:** André Klima

**Projektgruppe:** Alexander Fogus, Lea Vanheyden, Zorana Spasojevic

7. April 2020

Ludwig Maximilians Universität

1. Hintergrund
2. Datengrundlage
3. Aufgabenstellung
4. Binäre Regressionsmodelle
5. Probleme

# 1. Hintergrund

- Konfliktsituation zwischen Mensch und Natur/Tierreich im Alpengebiet
- Kooperation des Departments für Geographie an der LMU, Lawinencamp Bayern, Gebietsbetreuer Mangfallgebirge, Alpenregion Tegernsee/Schliersee und DAV Sektion München
- Speziellen Untersuchungen am Spitzingsee (beliebte Gegend für Sportler und Wildtiere)
- Wie verhalten sich die Besucher und wie kann man dieses Verhalten steuern?
- Dazu Untersuchung über die Mitnahme von LVS-Geräten anhand von Checkpoints und manueller Datenerhebung

## 2. Datengrundlage

- Untersuchungsgegenstand: Wintersportler (vorrangig Skitourenzügler & Schneeschuhgeher)
- Untersuchungszeitraum: Wintersaison 18/19
  - ↳ Genauer Zeitraum: 21.12.2018 - 12.04.2019
- Checkpoints an zwei Routen (Nord- und Südseite) erfassen:
  - ↳ Messungen insgesamt: 31574
  - ↳ Personen mit LVS-Gerät: 8468
  - ↳ Personen ohne LVS-Gerät: 23106

## 2. Datengrundlage

---

## 2. Datengrundlage

- Weitere Variablen:
  - ↳ Datum
  - ↳ Uhrzeit
  - ↳ Tageslänge
  - ↳ Temperatur
  - ↳ Schneehöhe
  - ↳ Sonnenstrahlung
  - ↳ Wochentag
  - ↳ Feiertag
  - ↳ Lawinenwarnstufe
- Durch manuelle Stichproben wurden die Messungen der Checkpoints als fehlerhaft erkannt

### 3. Aufgabenstellung

1. **Modell:** Anteil der Skitourengehänger mit LVS-Gerät in Abhängigkeit von anderen Faktoren (wie z.B. Uhrzeit, Temperatur, Schneehöhe)
2. Einflussfaktoren von denen die Messfehler abhängen, welcher Art und Struktur
3. Hypothese: Unter Berücksichtigung der Erkenntnisse über die Messfehler
  - ↳ Wie beeinflussen die Messfehler die geschätzten Abhängigkeiten?

## 4. Binäre Regressionsmodelle

### Daten

Die binäre Zielvariablen  $y_i$  sind 0/1-kodiert und bei gegebenen Kovariablen  $x_{i1}, \dots, x_{ik}$  (bedingt) unabhängig.

### Modelle

Die Wahrscheinlichkeit  $\pi_i = P(y_i = 1 | x_{i1}, \dots, x_{ik})$  und der lineare Prädiktor:

$$\eta_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik} = x_i' \beta$$

sind durch eine Responsefunktion  $h(\eta) \in [0, 1]$  miteinander verknüpft:

$$\pi_i = h(\eta_i).$$

(Quelle: Fahrmeir, Ludwig, et al. Regression; Prof. Dr. Helmut Küchenhoff Vorlesungsskript)



## 4. Binäre Regressionsmodelle

### Logit-Modell:

$$\pi = \frac{\exp(\eta)}{1 + \exp(\eta)} \iff \log \frac{\pi}{1 - \pi} = \eta.$$

Interpretation: log odds durch lineares Modell beschreibbar.

### Probit-Modell:

$$\pi = \Phi(\eta) \iff \Phi^{-1}(\pi) = \eta.$$

Interpretation: z-transformierte Wahrscheinlichkeiten sind durch lineares Modell beschreibbar.

Interpretation der  $\beta$  durch marginale Effekte

(Quelle: Fahrmeir, Ludwig, et al. Regression; Prof. Dr. Helmut Küchenhoff Vorlesungsskript )

## 4. Binäre Regressionsmodelle

---

- Gruppiertes Logit- oder Probit-Modell würden sich eignen
- Statistische Analysen mit Logit- und Probit-Modellen führen zu ähnlichen Resultaten

## 5. Probleme

### 1. Modellwahl

- ↳ Longitudinal-Data-Analysis: z.B. Schneehöhe an Tag 1 korreliert mit Schneehöhe an Tag 2
- ↳ Problem: Daten über gewissen Zeitraum gemessen, an manchen Tagen keine Messungen

### 2. Modellvergleich

- ↳ Logit- oder Probit-Modell
- ↳ Variablenselektion

### 3. Überdispersion

## 5.Probleme

### Überdispersion:

Für gruppierte Daten lässt sich die Varianz innerhalb der Gruppe abschätzen durch  $\frac{\bar{y}_i(1-\bar{y}_i)}{n_i}$ , da  $\bar{y}_i$  der ML-Schätzer für  $\pi_i$  basierend auf den Daten der Gruppe  $i$  ist.

### Problem:

In Anwendungen ist diese *empirische* Varianz oft deutlich größer als die durch ein binomiales Regressionsmodell vorhergesagte Varianz  $\frac{\hat{\pi}_i(1-\hat{\pi}_i)}{n_i}$  mit  $\hat{\pi}_i = h(\mathbf{x}_i'\beta)$ .

### Lösung:

Einführung eines multiplikativen Überdispersionsparameters  $\phi > 1$  in die Varianzformel, d.h.  $Var(y_i|\mathbf{x}_i) = \phi \frac{\pi_i(1-\pi_i)}{n_i}$

(Quelle: Fahrmeir, Ludwig, et al. Regression)