

Projekt LVS-IR-Taubenstein

Projektpartner: Sascha Filimon, Roman Ossner

Gruppenbetreuer: Dr. André Klima

Projektgruppe: Alexander Fogus, Lea Vanheyden, Zorana Spasojević

9. Mai 2020

Ludwig Maximilians Universität



1. Hintergrund
2. Datengrundlage
3. Modell
4. Ergebnisse
5. Messfehleranalyse
6. Sensitivitätsanalyse
7. Fazit
8. Anhang
9. Literaturverzeichnis



1.Hintergrund

- Konfliktsituation zwischen Mensch und Natur bzw. Tierreich im Alpengebiet
 - ↳ Vorallem Wildtiere stark betroffen
- Kooperation des Departments für Geographie an der LMU, Lawinencamp Bayern, Gebietsbetreuer Mangfallgebirge, Alpenregion Tegernsee/Schliersee und dem Deutschen Alpenverein München (DAV)
- Aktionstag
- Spezielle Untersuchungen am Spitzingsee
 - ↳ Territorium von Wildtieren
 - ↳ Beliebte Gegend für Sportler
- Untersuchung über die Mitnahme von LVS-Geräten anhand von Checkpoints und manueller Datenerhebung
 - ↳ Ziel: Das Verhalten der Besucher analysieren



1.Hintergrund

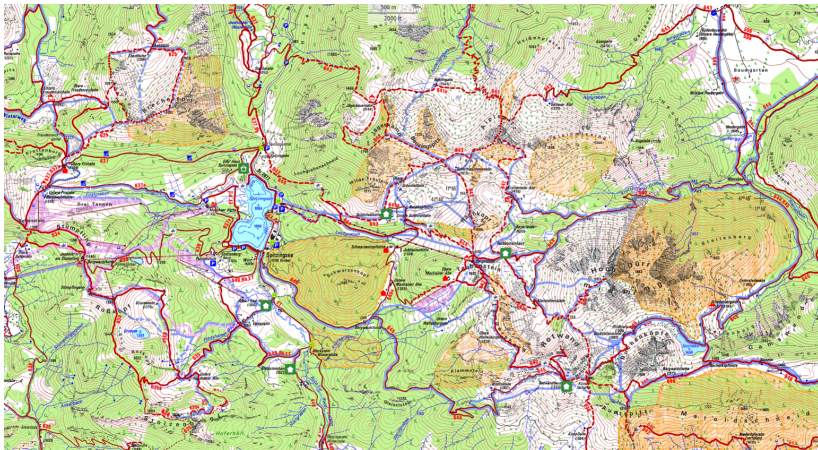


Abbildung 1: Untersuchungsraum: Spitzingsee



2.Datengrundlage

- Untersuchungsgegenstand: Wintersportler (vorrangig Skitourenzügler & Schneeschuhgeher)
- Untersuchungszeitraum der Checkpoints Wintersaison 18/19
 - ↳ Genauer Zeitraum: 25.12.2018 - 13.04.2019
- Checkpoints an zwei Routen (Nord- und Südseite) erfassen:
 - ↳ Messungen insgesamt: 37216
 - ↳ Personen mit LVS-Gerät: 8305
 - ↳ Personen ohne LVS-Gerät: 28911
- Untersuchungszeitraum der manuellen Erhebung am 27.02 und 28.02.2019



Zielvariable:

- Anteil der Personen mit und ohne LVS-Gerät

Kovariablen:

- Datum
- Tag der Woche
- Feiertag
- Schneehöhe (in *cm*)
- Temperatur (in $^{\circ}\text{C}$)
- Sonneneinstrahlung (in W/m^2)
- Lawinenwarnstufe
- Uhrzeit der Messung



2.Datengrundlage




Abbildung 2: Absolute Häufigkeit und Anteil der Personen mit und ohne LVS-Gerät nach Datum



2.Datengrundlage

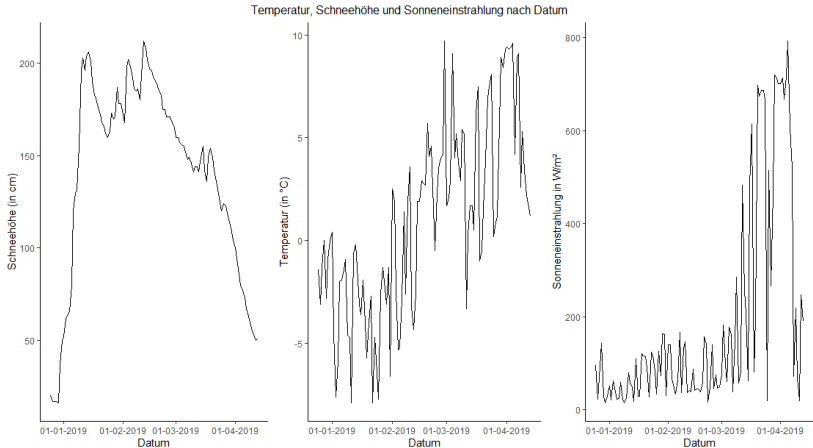


Abbildung 3: Temperatur, Schneehöhe und Sonneneinstrahlung nach Datum



2.Datengrundlage




Abbildung 4: Absolute Häufigkeit der Personen mit und ohne LVS-Gerät nach Uhrzeit



Umcodierung Variablen vllt.



Modell

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik} + \epsilon_i$$

- Erwartungswert einer Zufallsvariable wird durch Linearkombination von Kovariablen beschrieben
- Problem: Oft unzureichend, da auch nicht lineare Einflüsse auf Zielvariable wirken können



Standardmodell der additiven Regression:

$$y_i = \underbrace{f_1(z_{i1}) + \dots + f_q(z_{iq})}_{\text{nicht-parametrische Effekte}} + \underbrace{\beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik}}_{\text{parametrische Effekte}} + \epsilon_i$$

- Stellt ein nicht-parametrisches Regressionsmodell dar
- Vorteil: Neben linearen Effekten können auch nicht-lineare Einflüsse von Kovariablen auf Zielvariable modelliert werden



Penalisierte Splines basierend auf B-Splines

- Funktion f durch Spline modellieren
- Konstruktion des Penalisierten Splines durch B-Spline Basisfunktion und Strafterm



B-Spline Basisfunktion

- (a) Basisfunktion aus Polynomstücke des gewünschten Grades
↳ werden an den Knoten stetig zusammengesetzt
- (b) Basisfunktion skalieren
- (c) Skalierte Basisfunktionen addieren



B-Spline Basisfunktion

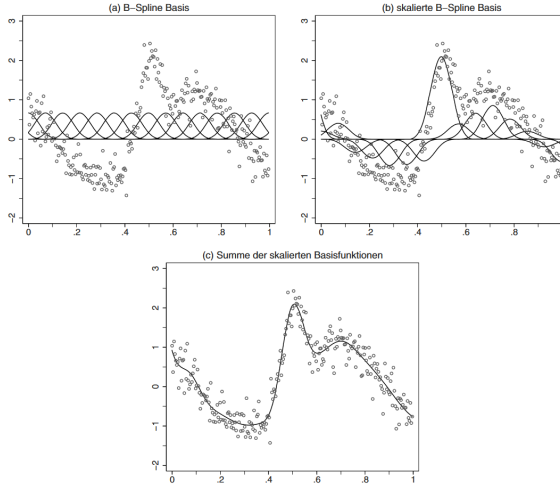


Abbildung 5: Visualisierung von B-Spline Basisfunktion anhand von fiktiven Daten



Strafterm

- Ziel: *Rauen* Schätzfunktionen entgegenwirken, d.h. zu starke Anpassung der Daten verhindern
- Bestrafung durch Glättungsparameter
- Für Glättungsparameter gegen ∞ , annähernd lineare Schätzfunktion



- Funktion der Variable Wochentag mit Hilfe von zyklischem P-Spline modelliert
- Werte am Ende einer Woche zusammenhängend zu den Werten am Anfang der Woche
- Beispiel: Sonntag und Montag



- Keine normalverteilte Zielvariable
- Zielvariable nimmt typischerweise Verteilung aus Exponentialfamilie an
 - ↳ Entweder normal-, binomial-, poisson- oder gammaverteilt



Zielgröße

Beobachtete Zielgröße ist Binomial-verteilt $y_i|x_i \sim B(1, \pi_i)$:

$$y_i = \begin{cases} 1 & \text{,wenn Person mit LVS-Gerät identifiziert wird} \\ 0 & \text{,wenn Person ohne LVS-Gerät identifiziert wird.} \end{cases}$$

Erwartungswert

Für den Erwartungswert der Zielvariable gilt:

$$E(y_i) = \pi_i = \frac{\exp(\eta_i)}{1 + \exp(\eta_i)} = h(\eta_i)$$

Logit-Link

$$\log(\pi_i) = \log\left(\frac{\pi_i}{1 - \pi_i}\right)$$



Additiver Prädiktor:

Der Erwartungswert μ der Zielvariable y wird mit dem additiven Prädiktor:

$$\eta_i = f_{1,2}(\text{Uhrzeit}_i, \text{Datum}_i)^* + f_3(\text{Lawinenwarnstufe}_i) + f_4(\text{Wochentag}_i) + f_5(\text{Temperatur_Residuen}_i)^{**} + f_6(\text{Sonneneinstrahlung_Residuen}_i)^{**} + f_7(\text{Schneehoehe_Residuen}_i)^{**} + \beta_0 + \beta_1(\text{Ferientag}_i)$$

*Bemerkung**: Modell kann durch Interaktionseffekt ergänzt werden

↳ Nicht-lineare Interaktion zwischen Datum und Uhrzeit

*Bemerkung*** : Smooth-Funktion für Residuen der Kovariablen Temperatur, Sonneneinstrahlung und Schnehöhe, da ansonsten

↳ *Concurvity*, stellt nicht-lineare Form der Kollinearität dar



Bzgl. Concurvity umcodierte Variablen



- Bisher: Betrachtung von Individualdaten
- Weitere Möglichkeit: Gruppierte Daten
 - ↳ Nach identische Zeilen der Kovariablen-Datenmatrix gruppieren (z.B. Datum)
- Problem: Überdispersion, d.h. Unterschätzung der Varianz
 - ↳ Lösung: Dispersionsparameter (ϕ)

Einführung eines Dispersionsparameters in Varianzformel

$$\text{Var}(y_i | \mathbf{x}_i) = \underbrace{\phi}_{\text{Dispersionsparameter}} \underbrace{\pi_i(1 - \pi_i)}_{\text{Varianz}}$$



Generalisierte additive (gemischte) Modell

- Aufbau wie generalisiertes additives Modell
- Miteinbeziehung von zufälligen Effekten
- Benötigt um Problem der Autokorrelation zu lösen
 - ↳ Korrelation einer Funktion mit sich selbst zu einem früheren Zeitpunkt



Zwei Modelle:

- Datumsmodell
 - ↳ Gruppierte Daten pro Tag
 - ↳ Uhrzeit der Messung nicht beachtet
- Zeitmodell
 - ↳ Gruppierte Daten pro Minute
 - ↳ Uhrzeit der Messung beachtet
 - ↳ Aber: Messungen nur einmal am Tag → niedrige Devianz



Datumsmodell

- plot Datumsmodell
- klar machen welche Signifikant sind
- außerdem intercept und deviance explained



Zeitmodell

- plot Zeitmodell
- klar machen welche Signifikant sind
- außerdem intercept und deviance explained



- Wissen aus Untersuchungen: Checkpointdaten haben Messfehler
- Neuen Daten zur Saison 19/20
 - ↳ Checkpointdaten: vollständig
 - ↳ Manuell erhobene Daten: nur 2 Tage
- Überlegung: Mögliche Szenarien für Messfehler erstellen und mögliche Änderungen im Modell prüfen



Plots zur deskriptiven Analyse



4 verschiedene Szenarien:

- Generelle Unterschätzung von 20%
- Unterschätzung nach Gruppengröße
- Nächtliche Überschätzung
- Unterschätzung bei niedrigen Temperaturen



Smooth-Vergleich zum ersten Szenario, stufenweise



Signifikanzvergleich zum ersten Szenario, stufenweise



B-Spline Basisfunktion

$$f(z) = \sum_{j=1}^d \gamma_j B_j(z), \text{ wobei } d = m + l - 1$$

$$B_j^l(z) = \frac{z - k_j}{k_{j+l} - k_j} B_j^{l-1}(z) + \frac{k_{j+l+1} - z}{k_{j+l+1} - k_{j+1}} B_{j+1}^{l-1}(z).$$

- Basisfunktion aus $(l + 1)$ Polynomstücke des gewünschten Grades (l)
↳ werden an den Knoten $(l - 1 - mal)$ stetig zusammengesetzt
- Basisfunktion $(B_j(z))$ mit dem Kleinste-Quadrate-Schätzer $\hat{\gamma}_j$ skalieren
- Skalierte Basisfunktionen addieren



Strafterm

$$\lambda \int (f'(z))^2 dz$$

- Ziel: *Rauen* Schätzfunktionen entgegenwirken, d.h. zu starke Anpassung der Daten verhindern
- Bestrafung durch Glättungsparameter λ
- Für $\lambda \rightarrow \infty$, annähernd lineare Schätzfunktion



